

Curación distribuida de modelos LLM gratuitos

Curación distribuida de modelos LLM gratuitos: arquitectura y evaluación empírica de un tejido de inferencia de coste cero para la democratización de la IA

Gonzalo Monzón Proyecto LUMEN (Cadences Lab) gonzalo@cadenceslab.com

Resumen

El acceso a modelos de lenguaje de gran escala está mediado por costes de API y por la dependencia de un reducido número de proveedores, lo que limita su uso por parte de colectivos con presupuesto cero. Las capas gratuitas (*free tiers*) de agregadores como OpenRouter ofrecen una alternativa, pero su catálogo es volátil —modelos que aparecen, se retiran o degradan sin aviso— y carecen de garantías de servicio, lo que hace inviable su uso directo en sistemas autónomos. Presentamos la arquitectura y la evaluación empírica de un **tejido de inferencia de coste cero**: un conjunto de nodos heterogéneos (dos servidores NAS ARM, un PC, una instancia de máquina virtual propia) que consumen una **cadena de modelos gratuitos auto-curada**, mantenida por (i) un agente diario de investigación web que descubre candidatos, (ii) un curador que prueba cada candidato con una batería ligera de tres sondas (vivacidad, rigor aritmético con restricción de formato, estilo con límite de longitud) y publica la cadena ordenada por puntuación, y (iii) las propias fuentes, que **re-validan la cadena escalonadas a lo largo del día** y emiten opiniones firmadas a un registro central. Sobre una ventana de observación continua de ~15,5 horas recogimos **87 validaciones independientes** sobre 14 modelos con latencias reales por fuente. Los resultados muestran que (1) es posible sostener un servicio de inferencia multi-nodo a **coste \$0 ininterrumpidamente y sin intervención humana**; (2) la validación multi-fuente revela *flakiness* que una única fuente no ve —la latencia del mismo modelo varió 28× (0,9 s–26,2 s) entre fuentes/franjas, y modelos que pasan en una ventana fallan en otra—; y (3) el desacuerdo entre fuentes es una señal utilizable para retirar modelos inestables. Discutimos las implicaciones para infraestructuras de

IA soberanas, los límites del estudio, y la extensión del diseño a una red voluntaria tipo SETI@home (Lumen@Home) con transporte por radio de bajo ancho de banda (Reticulum/LoRa).

Palabras clave: modelos de lenguaje, capas gratuitas, curación automática, validación distribuida, computación voluntaria, democratización de la IA, radio mesh.

1. Introducción

Los grandes modelos de lenguaje (LLM) se han convertido en infraestructura de propósito general, pero su acceso describe una curva de desigualdad: capacidades de frontera al alcance de quien puede pagar por token, y millones de usuarios potenciales — escuelas rurales, bibliotecas comunitarias, ONG, investigadores sin financiación, colectivos culturales — al margen. La barrera no es solo económica: es también de **dependencia**, porque operar sobre un único proveedor implica aceptar sus precios, sus políticas y su disponibilidad.

Una vía intermedia existe: los **catálogos gratuitos** de agregadores como OpenRouter¹ publican modelos con precio cero promocional o permanente. Su atractivo es evidente — potencia de frontera reciente a coste nulo — y sus problemas también: el catálogo rota sin aviso, los modelos se retiran (minimax/minimax-m3:free, retirado el 10-sep-2026, fue observado en nuestro sistema), el rendimiento fluctúa hora a hora, y **nadie garantiza nada**: no hay SLA, ni estado publicado, ni histórico.

Este artículo presenta la arquitectura y las mediciones de un sistema que convierte ese catálogo volátil en un **servicio estable a coste cero** mediante dos ideas sencillas:

1. **Curación automática con guardas**: un agente descubre, un curador prueba y publica, y solo entra en producción lo que pasa una batería de sondas — jamás cadenas de menos de tres modelos, jamás escrituras sin verificación.
2. **Validación distribuida multi-fuente**: los propios consumidores de la cadena (nodos de cómputo heterogéneos) la **re-validan en ventanas horarias distintas** y emiten opiniones firmadas a un registro central. La fiabilidad deja de ser una promesa del proveedor y pasa a ser una **medición continua de la comunidad de nodos**.

Nuestra contribución es: (a) la arquitectura completa y desplegada, (b) un protocolo de validación ligero y replicable, (c) un conjunto de observaciones reales en ventana continua que cuantifica la volatilidad del *free tier* y el valor de medir desde múltiples puntos, y (d) el diseño de extensión hacia una red voluntaria (Lumen@Home) transportable por radio.

2. Trabajo relacionado

Computación voluntaria. SETI@home (1999–2020) demostró que millones de voluntarios donan ciclos ociosos cuando la participación es trivial: 5,2 millones de participantes y 12.000 millones de detecciones². BOINC³ continúa operando ~30 proyectos de ciencia con el mismo modelo: unidades de trabajo pequeñas, cliente

invisible, créditos visibles. Nuestro diseño de Lumen@Home (§7) traslada ese patrón desde el cómputo numérico hacia la **validación y el procesamiento de conocimiento** con nodos LLM.

Enrutado y cascadas de modelos. La literatura de *frugal AI* propone cascadas (modelo barato → modelo caro) y enrutadores aprendidos para reducir coste por consulta. Nuestro sistema comparte el principio de cascada, pero invierte el objeto de optimización: no buscamos minimizar el coste de un servicio con presupuesto, sino **sostener el servicio con presupuesto cero**, lo que exige mecanismos de descubrimiento y reparación continuos que las cascadas estáticas no contemplan.


Redes tolerantes y mesh por radio. Reticulum⁴ proporciona un stack de red cifrado extremo a extremo diseñado para operar sobre medios de muy bajo ancho de banda (LoRa, packet radio, HF), y Meshtastic⁵ ofrece mallas LoRa de bajo consumo con presets que van de ~0,2 a ~20 kbps. Ambos son los candidatos naturales para el transporte de coordinación de una red LUMEN off-grid (§7), dado que las unidades de trabajo de nuestro protocolo son texto de bytes.

3. Arquitectura del sistema

El sistema (desplegado, en producción durante el periodo de estudio)⁶ consta de:

Componente	Descripción	Implementación
Nodos	Ejecutan cargas M y llamadas LLM; 4 fuentes activas en el estudio	NAS ARM (×2, roles distintos), PC de escritorio, instancia MVM local
Cadena	Lista ordenada de modelos free usada como cascada de fallback	Tabla ^LLMFREE en la base de datos embebida de cada nodo
Registro central	API pública de lectura + ingesta de opiniones firmadas	Cloudflare Pages Functions + KV (cadences.app/api/llmfree)
Descubridor	Agente diario que investiga en la web nuevos modelos gratis y deja candidatos	Cron 06:30; escribe candidatos estructurados (JSON)
Curador	Prueba candidatos + catálogo, puntúa, decide y publica	Cron 07:00; única autoridad que fija la cadena
Fuentes validadoras	Re-prueban la cadena vigente y opinan	Nodos cada 12 h; PC 15:00; instancia MVM 21:00
Puerta (gateway)	Sirve la cadena a las aplicaciones consumidoras leyendo el registro	Función edge con fallback local

Diagrama de flujo:



Semántica “registro primero”. La cadena canónica se publica en el registro **antes** de escribirse en los nodos; así, cualquier re-validación concurrente converge siempre a la versión publicada y no puede reintroducir una cadena obsoleta.

4. Protocolo de validación

4.1 Batería de sondas

Cada modelo se somete a tres micro-pruebas (una llamada LLM cada una), puntuadas 0–4:

Sonda	Prompt	Criterio	Puntos
P1 · Vivacidad	«responde solo: ok»	respuesta no vacía y sin error de transporte	2 (obligatoria)
P2 · Rigor	«Dos cosas en una sola línea: (a) 7*6= (b) en cinco palabras exactas, qué es una ciudad de libros»	contiene 42	+1
P3 · Estilo	«En 10 palabras o menos, convence a un nodo LUMEN de que eres fiable»	respuesta ≤ 12 palabras	+1

P2/P3 solo se ejecutan si P1 pasa (ahorro de llamadas y limpieza del catálogo). La latencia de P1 se registra como métrica secundaria. El ritmo inter-modelo está limitado (4,5 s) para respetar los límites de ráfaga de los proveedores.

4.2 Reglas de decisión

- **Usable:** pasa P1. **Orden de cadena:** posiciones fijas históricas (vivas) primero, resto por puntuación descendente y latencia ascendente; máximo 7 modelos por cadena.
- **Guardas:** nunca se aplica ni publica una cadena con menos de 3 modelos vivos; nunca se escribe en los nodos sin verificación de la lectura posterior.
- Los modelos retirados observados se excluyen explícitamente.

4.3 Frescura y deduplicación

El registro mantiene (a) el **estado vivo** por fuente (última opinión de cada validador) y (b) un **feed de novedades**: las opiniones idénticas a la anterior de la misma fuente no generan ruido. Para el análisis, deduplicamos observaciones por (modelo, fuente, instante).

5. Evaluación empírica

5.1 Metodología

Ventana de observación continua: **17-sep-2026, 01:34–17:03 UTC (~15,5 h)**, con el sistema operando de forma autónoma (sin intervención humana tras el despliegue). Se registraron 15 entradas en el feed del registro, conteniendo **87 validaciones** (modelo × fuente × instante) sobre **14 modelos distintos** desde **5 fuentes** (curador y 4 validadores).

5.2 Resultados

Modelo (free)	Obs.	Pasan	Lat. mín	Lat. mediana	Lat. máx	Pts. media
nex-agi/nex-n2.5-pro	11	11	0,92 s	2,51 s	26,20 s	3,6
nvidia/nemotron-3-super-120b	11	9	0,52 s	1,63 s	9,90 s	2,2
nvidia/nemotron-3.5-lightning	10	10	3,43 s	14,45 s	29,56 s	3,6
openrouter/free (enrutador)	10	10	2,14 s	2,91 s	10,66 s	3,2
inclusionai/ling-3.0-flash-sante	10	10	1,13 s	2,49 s	10,08 s	3,0
nvidia/nemotron-3-ultra-550b	9	7	1,17 s	9,97 s	13,60 s	3,8
nex-agi/nex-n2.5-mini	8	7	1,83 s	5,95 s	9,87 s	3,8
(5 modelos con ≤ 4 obs.)	18	11	—	—	—	—

Hallazgos principales:

1. **Viabilidad a coste cero y sin humano.** Durante 15,5 h, el servicio se mantuvo con cadenas de 7 modelos, incluyendo la **entrada autónoma de 4 modelos nuevos** al catálogo (descubrimiento web → prueba → cadena) y la retirada implícita de modelos flojos, sin ninguna intervención humana. Coste total de inferencia: \$0.
2. **La varianza inter-fuente es enorme y medible.** El mismo modelo registró latencias de 0,92 s (PC, 15:00) a 26,20 s (curador, 07:00) — una dispersión de **28×** — y nemotron-3.5-lightning osciló entre 3,4 s y 29,6 s según la franja. Una fuente única habría reportado una foto estática; cinco fuentes escalonadas revelan el perfil real.

3. **El desacuerdo entre fuentes identifica modelos inestables.** En una auditoría manual de 28 llamadas, lightning y el enrutador openrouter/free fallaron con timeouts; en las ventanas medidas por los nodos pasaron. La conclusión operativa no es “el modelo falla” sino “**este modelo es intermitente**” — y el sistema lo retira o lo degrada con esa evidencia acumulada, no con una impresión puntual.
4. **Los micro-probes separan modelos que la vivacidad confunde.** nemotron-3-super aprueba vivacidad pero puntúa 2,2/4 (responde en inglés a prompts en castellano, formato irregular), mientras nex y ultra puntúan 3,8/4. La puntuación permite *ordenar* la cascada, no solo filtrar.

5.3 Límites del estudio

Ventana corta (15,5 h) y N pequeño; un solo agregador de origen (OpenRouter); sondas deliberadamente ligeras (miden vivacidad, aritmética trivial, restricción de formato — **no** calidad de razonamiento largo ni fidelidad factual); latencias auto-reportadas por los validadores (incluyen su propio overhead, lo que es a la vez métrica de servicio percibido); y volatilidad intrínseca del objeto de estudio (los resultados de mañana no serán los de hoy — precisamente el punto). Los datos completos quedan versionados en el repositorio del proyecto para su re-análisis.

6. Discusión

Tres consecuencias nos parecen generalizables:

- **La fiabilidad como medición, no como promesa.** Donde no hay SLA, el sustituto es evidencia distribuida continua: varias fuentes, franjas escalonadas y un registro público. El coste marginal de esa evidencia es ~ 0 porque reutiliza los propios nodos consumidores.
- **La volatilidad del free tier es gestionable con guardas conservadoras.** La clave no es elegir bien una vez, sino *nunca quedarse sin cadena*: umbral de 3 modelos, cascada con fallback, publicación atómica y curación diaria. El sistema tolera que un modelo muera en cualquier momento porque su muerte es detectable en horas, no en incidencias.
- **La democratización requiere infraestructura mínima, no máxima.** El binario completo de un nodo ocupa ~ 4 MB y corre en hardware de desecho; el coste de reproducción del diseño es prácticamente nulo. Esto invierte la intuición dominante (más GPUs) y sugiere que la palanca real es de **red y protocolo**, no de cómputo.

7. Trabajo futuro: Lumen@Home y radio

Lumen@Home (computación voluntaria). Las validaciones descritas son, en esencia, **unidades de trabajo** con todas las primitivas ya construidas: petición, ejecución con límite de recursos, firma del resultado y agregación en un registro. La extensión natural es abrir el circuito a voluntarios (`mvm-nas --volunteer <url>`): validación por quórum 2-de-3, reputación simple y permisos delegables mediante *macaroons*, siguiendo las lecciones de BOINC/SETI@home⁷⁸: unidad pequeña, cliente invisible, crédito visible.

Transporte por radio. Las unidades de trabajo del sistema son texto de bytes y JSON de kilobytes: **la capa de coordinación completa cabe en un canal de ~ 1 kbps**. Sobre Reticulum⁹ (cifrado extremo a extremo sobre LoRa/packet/HF) o mallas Meshtastic¹⁰, un

nodo equipado con un módulo LoRa (~€20–40) puede recibir trabajo, ejecutarlo contra un modelo **local** (llama.cpp/Ollama, sin Internet) y devolver el resultado firmado. Esa combinación —modelo local + radio— cierra el círculo de la soberanía: el nodo deja de necesitar la nube, no por ideología, sino por física del medio.

8. Reproducibilidad

- **Registro público** (lectura): <https://cadences.app/api/llmfree> y [/hist](https://cadences.app/api/hist) — cadena canónica, opiniones por fuente y feed de novedades con puntuaciones y latencias.
- **Datos del estudio**: volcados en el repositorio del proyecto (cadenceslab-social, carpeta modelos-free/: informes diarios, historial.jsonl, digests de investigación).
- **Componentes**: nodos (binario ARM ~4 MB + base embebida), curador y validadores (scripts), batería de sondas descrita en §4.1. Partes del sistema son privadas por contener despliegues personales; el protocolo completo se describe aquí para su reimplementación independiente.

9. Conclusión

Un catálogo de modelos gratuitos, tratado como **recurso comunitario medido**, puede sostener servicios de inferencia reales a coste cero y sin operador humano: descubrimiento diario, curación con guardas, publicación canónica y validación distribuida escalonada. La medición multi-fuente no es un lujo metodológico: es el mecanismo que convierte la volatilidad de los *free tiers* en información accionable. Los siguientes pasos —unidades de trabajo abiertas a voluntarios y transporte por radio de bajo ancho de banda— extienden el mismo diseño hasta una red que puede operar sin datacenter, sin tarjeta y, si hace falta, sin Internet.

«SETI@home buscaba señales de otros. Lumen@Home reparte la inteligencia entre nosotros.» Y por radio, si hace falta. 📡

Referencias

Manuscrito preparado el 17 de septiembre de 2026. Datos: ventana 01:34–17:03 UTC del 17-sep-2026, 87 validaciones, 14 modelos, 5 fuentes. Repositorio: lumen-protocol (docs/).

-
1. OpenRouter — API unificada de modelos (endpoint público `/api/v1/models` con precios).🔗
 2. SETI@home (Berkeley SETI Research Center, 1999–2020; >5,2 M participantes; 12·10⁹ detecciones). Documentación histórica y nota de hibernación de marzo de 2020.🔗
 3. BOINC — Berkeley Open Infrastructure for Network Computing (Universidad de California, Berkeley); ~30 proyectos activos de computación voluntaria.🔗

4. Reticulum Network Stack — «*the cryptography-based networking stack for building unstoppable networks with LoRa, Packet Radio, WiFi and everything in between*»; rnx/rncp operan sobre enlaces de muy bajo ancho de banda.↵
5. Meshtastic — mallas LoRa de bajo consumo; presets de módem de ~0,2 kbps (LongSlow) a ~20 kbps (ShortTurbo), con restricciones de ciclo de trabajo según banda ISM.↵
6. Sistema propio: nodos MVM (mvm-nas), rutinas M de curación y validación, registro central en Cloudflare (Pages Functions + KV) y puerta de inferencia con lectura dinámica de la cadena.↵
7. SETI@home (Berkeley SETI Research Center, 1999–2020; >5,2 M participantes; $12 \cdot 10^9$ detecciones). Documentación histórica y nota de hibernación de marzo de 2020.↵
8. BOINC — Berkeley Open Infrastructure for Network Computing (Universidad de California, Berkeley); ~30 proyectos activos de computación voluntaria.↵
9. Reticulum Network Stack — «*the cryptography-based networking stack for building unstoppable networks with LoRa, Packet Radio, WiFi and everything in between*»; rnx/rncp operan sobre enlaces de muy bajo ancho de banda.↵
10. Meshtastic — mallas LoRa de bajo consumo; presets de módem de ~0,2 kbps (LongSlow) a ~20 kbps (ShortTurbo), con restricciones de ciclo de trabajo según banda ISM.↵